LAPORAN PROJECT MACHINE LEARNING

MEMPREDIKSI PERGERAKAN

HARGA SAHAM

Dosen Pengampu:

[Asep Erlana Maulana S.kom,M.kom.]

Disusun oleh:

Muhammad Aditya Nugraha NIM:

241011400849

Kelas: 05 TPLP 021

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PAMULANG
Jl. Raya Puspitek, Buaran, Kec. Pamulang, Kota Tanggerang Selatan, Banten 19310

2026

RINGKASAN

Pergerakan harga saham merupakan fenomena yang dipengaruhi oleh banyak faktor, antara lain kondisi perusahaan, aktivitas perdagangan, sentimen investor, suku bunga, nilai tukar, kebijakan pemerintah, dan keadaan ekonomi global. Karena data saham berbentuk deret waktu (time series) dan memiliki volatilitas tinggi, analisis dataset perlu dilakukan secara sistematis sebelum model prediksi dibangun.

Materi ini membahas tahapan analisis dataset untuk memprediksi pergerakan harga saham: perumusan masalah, pengumpulan data, pemahaman variabel, pembersihan data, eksplorasi data, pembentukan fitur, pembagian data berdasarkan waktu, pemilihan model, evaluasi, serta interpretasi hasil. Contoh yang digunakan bersifat ilustratif untuk kebutuhan pembelajaran, bukan hasil eksperimen terhadap saham tertentu.

Tujuan utama bukan menjanjikan prediksi yang selalu benar, melainkan menunjukkan bagaimana data historis dapat digunakan untuk membuat estimasi yang terukur, mengevaluasi ketidakpastian, dan menghindari kesalahan metodologis seperti kebocoran data (data leakage). Hasil model tidak boleh dianggap sebagai rekomendasi investasi.

Sistematika Materi

- BAB I — Pendahuluan
- BAB II — Konsep Dasar Saham dan Dataset
- BAB III — Metodologi Analisis Dataset
- BAB IV — Pemodelan Prediksi Pergerakan Harga
- BAB V — Evaluasi dan Interpretasi Hasil
- BAB VI — Contoh Analisis Ilustratif
- BAB VII — Kesimpulan dan Saran

BAB I — PENDAHULUAN

1.1 Latar Belakang

Pasar saham menghasilkan data dalam jumlah besar setiap hari. Data tersebut meliputi harga pembukaan, harga tertinggi, harga terendah, harga penutupan, volume transaksi, dan informasi lain yang tersedia pada periode tertentu. Data historis ini dapat dianalisis untuk memahami pola pergerakan harga serta membangun model yang memperkirakan harga atau arah pergerakan pada periode berikutnya.

Kemajuan komputasi dan machine learning memungkinkan proses analisis dilakukan dengan metode statistik maupun algoritma pembelajaran mesin. Namun, harga saham sulit diprediksi karena pola pasar dapat berubah, data mengandung noise, dan informasi baru dapat mengubah perilaku investor. Studi terkini juga menekankan pentingnya validasi yang sesuai urutan waktu serta evaluasi yang realistis sebelum hasil prediksi ditafsirkan lebih jauh.

1.2 Rumusan Masalah

1. Apa saja karakteristik dan variabel penting dalam dataset harga saham?
2. Bagaimana tahapan mempersiapkan dataset sebelum digunakan untuk pemodelan?
3. Metode apa yang dapat digunakan untuk memprediksi harga atau arah pergerakan saham?
4. Bagaimana cara mengevaluasi hasil model secara adil dan menghindari bias?

1.3 Tujuan

- Menjelaskan struktur dataset harga saham dan variabel yang umum digunakan.
- Menguraikan tahapan pembersihan, eksplorasi, dan rekayasa fitur.
- Mengenalkan metode prediksi statistik dan machine learning.
- Menjelaskan pembagian data berbasis waktu dan metrik evaluasi.
- Menyusun contoh alur analisis yang dapat diterapkan dalam tugas kuliah.

1.4 Manfaat

Materi ini membantu mahasiswa memahami proses analisis data keuangan, meningkatkan kemampuan berpikir kritis terhadap hasil model, dan mengenali batasan prediksi pada data yang dinamis. Materi juga dapat menjadi kerangka awal untuk proyek data science berbasis deret waktu.

BAB II — KONSEP DASAR SAHAM DAN DATASET

2.1 Pengertian Saham dan Pergerakan Harga

Saham adalah bukti kepemilikan atas suatu perusahaan. Harga saham terbentuk melalui aktivitas permintaan dan penawaran di pasar. Perubahan harga dari satu periode ke periode lain disebut pergerakan harga. Pergerakan dapat dianalisis dalam bentuk harga numerik, persentase return, atau kelas arah seperti naik, turun, dan relatif tetap.

2.2 Struktur Dataset Harga Saham

Dataset saham umumnya disusun menurut tanggal atau waktu transaksi. Setiap baris mewakili satu periode, misalnya satu hari perdagangan, sedangkan kolom mewakili atribut yang diamati.

Variabel	Penjelasan	Kegunaan
Date / Timestamp	Tanggal atau waktu observasi	Menjaga urutan data dan menentukan periode
Open	Harga pada awal periode perdagangan	Mengamati perubahan sejak pembukaan
High	Harga tertinggi dalam periode	Menggambarkan rentang pergerakan atas
Low	Harga terendah dalam periode	Menggambarkan rentang pergerakan bawah
Close	Harga penutupan periode	Target umum untuk prediksi harga
Adjusted Close	Harga penutupan yang disesuaikan untuk aksi korporasi tertentu	Membantu analisis historis yang disesuaikan
Volume	Jumlah saham yang diperdagangkan	Menggambarkan intensitas aktivitas perdagangan

2.3 Jenis Target Prediksi

- Regresi harga: memperkirakan nilai harga penutupan pada hari berikutnya.
- Prediksi return: memperkirakan perubahan relatif harga, bukan hanya nominalnya.
- Klasifikasi arah: memprediksi apakah harga akan naik atau turun pada periode berikutnya.

2.4 Sumber Data

Data dapat diperoleh dari penyedia data pasar, situs bursa, API keuangan, atau dataset terbuka seperti data historis yang disediakan untuk tujuan pendidikan. Sebelum digunakan, peneliti perlu memeriksa lisensi, kelengkapan, zona waktu, penyesuaian aksi korporasi, dan apakah data mencakup hari tanpa perdagangan.

BAB III — METODOLOGI ANALISIS DATASET

3.1 Alur Kerja Penelitian

5. Menentukan pertanyaan penelitian dan target prediksi.
6. Mengumpulkan data historis dari sumber yang dapat dipertanggungjawabkan.
7. Memeriksa struktur kolom, tipe data, rentang tanggal, dan duplikasi.
8. Membersihkan nilai hilang atau anomali berdasarkan alasan yang jelas.
9. Melakukan eksplorasi data melalui statistik deskriptif dan visualisasi.
10. Membentuk fitur yang hanya menggunakan informasi yang tersedia pada waktu prediksi.
11. Membagi data secara kronologis menjadi data latih, validasi, dan uji.
12. Melatih model dasar dan model pembanding.
13. Mengevaluasi prediksi, membandingkannya dengan baseline, lalu melaporkan keterbatasan.

3.2 Pengumpulan dan Pemeriksaan Data

Langkah pertama adalah menetapkan saham yang dianalisis, rentang waktu, frekuensi data, dan horizon prediksi. Contohnya, target dapat ditetapkan sebagai harga penutupan satu hari perdagangan berikutnya. Pemeriksaan awal mencakup jumlah baris, nama kolom, tipe data, tanggal yang berulang, nilai kosong, serta harga atau volume yang tidak masuk akal.

3.3 Pembersihan Data

Data yang tidak lengkap tidak boleh langsung dihapus tanpa pemeriksaan. Nilai kosong mungkin terjadi karena hari libur bursa, gangguan pengambilan data, atau atribut tertentu yang tidak tersedia. Duplikasi tanggal dapat menyebabkan pembobotan yang salah. Nilai ekstrem perlu diperiksa apakah merupakan pergerakan pasar yang nyata atau kesalahan pencatatan.

3.4 Data Leakage

Data leakage terjadi ketika proses pelatihan secara tidak sengaja memakai informasi yang seharusnya belum tersedia pada saat prediksi. Contohnya, menggunakan harga penutupan hari esok sebagai fitur untuk memprediksi harga hari esok, atau melakukan normalisasi pada seluruh dataset sebelum pembagian data. Untuk menghindarinya, fitur dan parameter preprocessing harus dihitung menggunakan data latih saja, kemudian diterapkan pada data berikutnya.

BAB III — EKSPLORASI DAN REKAYASA FITUR

3.5 Exploratory Data Analysis (EDA)

EDA adalah tahap untuk memahami karakteristik dataset sebelum membangun model. EDA membantu menemukan tren, perubahan volatilitas, data kosong, pencilan, dan hubungan antarkolom.

- Statistik deskriptif: nilai minimum, maksimum, rata-rata, median, dan simpangan baku.
- Grafik garis harga penutupan: melihat tren dan perubahan harga dari waktu ke waktu.
- Grafik volume: menemukan periode dengan aktivitas perdagangan tinggi atau rendah.
- Histogram return: memahami distribusi perubahan harga dan kemungkinan nilai ekstrem.
- Korelasi fitur: melihat hubungan antarvariabel, dengan tetap memperhatikan bahwa korelasi bukan bukti sebab-akibat.

3.6 Rekayasa Fitur (Feature Engineering)

Feature engineering membentuk variabel baru yang dapat membantu model mengenali pola historis. Semua fitur harus dihitung dari informasi yang sudah tersedia pada waktu prediksi.

Fitur	Contoh rumus / definisi	Tujuan
Return harian	(Close_t − Close_(t−1)) / Close_(t−1)	Mengukur perubahan relatif
Moving Average 5 hari	Rata-rata Close lima periode sebelumnya	Menghaluskan fluktuasi jangka pendek
Volatilitas bergulir	Simpangan baku return pada jendela tertentu	Mengukur variasi return
Lag 1	Harga penutupan periode sebelumnya	Menyediakan konteks historis
Perubahan volume	Volume_t dibanding Volume_(t−1)	Mengukur perubahan aktivitas

3.7 Normalisasi dan Skala

Sebagian algoritma sensitif terhadap skala fitur. Min-Max Scaling memetakan nilai ke rentang tertentu, sedangkan standardisasi mengubah fitur berdasarkan rata-rata dan simpangan baku. Parameter skala dihitung hanya dari data latih untuk mencegah kebocoran informasi. Untuk model berbasis pohon, normalisasi biasanya tidak sepenting pada model yang menggunakan jarak atau optimasi gradien.

BAB IV — PEMODELAN PREDIKSI PERGERAKAN HARGA

4.1 Model Baseline

Model baseline adalah pembanding sederhana yang harus dikalahkan oleh model yang lebih kompleks. Untuk prediksi harga satu hari ke depan, baseline yang umum adalah menggunakan harga penutupan terakhir sebagai prediksi berikutnya. Baseline penting karena harga saham sering memiliki persistensi tinggi; model kompleks yang tidak mengungguli baseline belum tentu memberi manfaat.

4.2 Metode Statistik

- ARIMA: memodelkan pola deret waktu melalui komponen autoregresif, differencing, dan moving average. Cocok sebagai pembanding untuk pola yang dapat dijelaskan oleh struktur temporal tertentu.
- GARCH: digunakan terutama untuk memodelkan perubahan volatilitas atau varians return yang tidak konstan.

4.3 Machine Learning

- Linear Regression: sederhana dan mudah dijelaskan, tetapi kurang mampu menangkap pola nonlinier yang rumit.
- Random Forest: menggabungkan banyak pohon keputusan dan dapat menangani hubungan nonlinier pada fitur tabular.
- Gradient Boosting: membangun model bertahap untuk memperbaiki kesalahan model sebelumnya; perlu pengaturan parameter agar tidak overfit.
- Support Vector Regression (SVR): memodelkan hubungan menggunakan margin dan kernel; sensitif terhadap skala dan pemilihan parameter.

4.4 Deep Learning: LSTM

Long Short-Term Memory (LSTM) adalah jenis jaringan saraf berulang yang dirancang untuk mempelajari ketergantungan berurutan. LSTM dapat memproses jendela harga historis dan fitur lain untuk menghasilkan prediksi. Model ini membutuhkan data yang memadai, pemilihan parameter yang cermat, dan pembandingan dengan baseline. Kompleksitas yang lebih tinggi tidak otomatis menghasilkan prediksi lebih baik.

4.5 Memilih Model

Pemilihan model ditentukan oleh tujuan, jumlah data, horizon prediksi, kebutuhan interpretasi, dan sumber daya komputasi. Untuk proyek awal, pendekatan yang disarankan adalah membangun baseline, mencoba satu atau dua model yang dapat dijelaskan, lalu menambahkan model kompleks jika ada alasan yang jelas.

BAB IV — PEMBAGIAN DATA DAN PELATIHAN MODEL

4.6 Pembagian Data Berbasis Waktu

Karena data saham berurutan menurut waktu, pembagian data harus mempertahankan kronologi. Contoh pembagian adalah 70% periode awal untuk pelatihan, 15% berikutnya untuk validasi, dan 15% terakhir untuk pengujian. Persentase tersebut hanya contoh; ukuran yang tepat bergantung pada jumlah data dan tujuan penelitian.

Bagian	Fungsi	Aturan utama
Training	Mempelajari pola dari data historis	Berisi periode paling awal
Validation	Memilih model dan parameter	Terjadi setelah periode training
Testing	Menilai performa akhir pada data yang belum digunakan	Diletakkan paling akhir dan tidak dipakai untuk tuning

4.7 Walk-Forward Validation

Walk-forward validation menguji model secara berulang mengikuti urutan waktu. Model dilatih menggunakan data yang tersedia hingga waktu tertentu, lalu memprediksi periode sesudahnya. Setelah observasi baru tersedia, jendela pelatihan dapat diperluas atau digeser. Metode ini lebih menyerupai kondisi nyata dibanding pembagian acak karena tidak memakai data masa depan untuk memprediksi masa lalu.

4.8 Pelatihan dan Tuning

Parameter model ditentukan menggunakan data training dan validation. Contohnya, Random Forest dapat diuji dengan beberapa nilai jumlah pohon dan kedalaman maksimum. LSTM dapat diuji dengan ukuran jendela, jumlah unit, batch size, dan jumlah epoch. Pengujian parameter harus dilakukan tanpa menyentuh data testing. Setelah keputusan final dibuat, hasil pada testing dilaporkan satu kali sebagai evaluasi akhir.

4.9 Menjaga Reproduksibilitas

Catat sumber data, tanggal pengunduhan, rentang periode, definisi target, daftar fitur, metode preprocessing, pembagian data, parameter model, dan metrik evaluasi. Catatan tersebut memudahkan orang lain memeriksa atau mengulang analisis.

BAB V — EVALUASI DAN INTERPRETASI HASIL

5.1 Metrik Regresi

Untuk prediksi nilai harga, kesalahan dapat dihitung dengan membandingkan nilai aktual dan prediksi. Metrik yang berbeda menyoroti aspek kesalahan yang berbeda.

Metrik	Rumus ringkas	Interpretasi
MAE	Rata-rata |aktual − prediksi|	Rata-rata besar kesalahan absolut
MSE	Rata-rata (aktual − prediksi)²	Memberi penalti besar pada kesalahan besar
RMSE	Akar kuadrat MSE	Satuan sama dengan target harga
MAPE	Rata-rata persentase kesalahan absolut	Mudah dibaca sebagai persen, tetapi bermasalah jika aktual nol atau mendekati nol

5.2 Metrik Klasifikasi Arah

Jika targetnya naik atau turun, metrik dapat mencakup accuracy, precision, recall, F1-score, dan confusion matrix. Accuracy menunjukkan proporsi prediksi yang benar, tetapi dapat menyesatkan jika kelas tidak seimbang. Karena itu, metrik perlu dipilih sesuai tujuan dan distribusi kelas.

5.3 Contoh Perhitungan MAE

Misalnya harga aktual pada tiga hari adalah Rp1.000, Rp1.020, dan Rp1.010, sedangkan prediksi model adalah Rp990, Rp1.030, dan Rp1.000. Kesalahan absolutnya masing-masing Rp10, Rp10, dan Rp10. MAE = (10 + 10 + 10) / 3 = Rp10. Ini hanya contoh angka untuk menjelaskan rumus, bukan hasil dari saham nyata.

5.4 Evaluasi Finansial

Akurasi statistik tidak otomatis berarti strategi perdagangan menguntungkan. Jika model digunakan untuk simulasi strategi, perlu diperhitungkan biaya transaksi, spread, slippage, pajak atau biaya lain yang relevan, serta risiko. Metrik seperti return kumulatif, volatilitas, Sharpe ratio, dan maximum drawdown dapat melengkapi evaluasi, tetapi memerlukan asumsi strategi yang eksplisit.

5.5 Interpretasi yang Bertanggung Jawab

Laporkan hasil dengan menyebutkan periode data, horizon prediksi, metrik, baseline pembanding, dan keterbatasan. Hindari klaim bahwa model dapat memastikan harga masa depan. Model dapat gagal ketika kondisi pasar berubah, ada peristiwa tak terduga, atau pola historis tidak berulang.

BAB VI — CONTOH ANALISIS ILUSTRATIF

6.1 Skenario Penelitian

Skenario: mahasiswa ingin menguji apakah data harga penutupan harian dapat membantu memprediksi harga penutupan satu hari perdagangan berikutnya. Dataset contoh memiliki kolom Date, Open, High, Low, Close, dan Volume. Untuk menjaga fokus, target awal adalah Close pada hari berikutnya.

6.2 Rancangan Eksperimen

Komponen	Rancangan ilustratif
Unit analisis	Satu saham, data harian
Target	Harga Close pada hari perdagangan berikutnya
Fitur awal	Lag Close 1, return harian, moving average 5 hari, volume
Baseline	Prediksi besok sama dengan Close terakhir yang tersedia
Model pembanding	Linear Regression dan Random Forest
Pembagian	70% training, 15% validation, 15% testing secara kronologis
Metrik utama	MAE dan RMSE
Validasi tambahan	Walk-forward validation jika waktu dan data memungkinkan

6.3 Contoh Data Mini

Tanggal	Close (Rp)	Volume	Catatan
Hari 1	1.000	12.000	Observasi awal
Hari 2	1.010	14.500	Harga naik
Hari 3	1.005	13.100	Harga turun tipis
Hari 4	1.020	17.800	Aktivitas meningkat
Hari 5	1.015	15.200	Harga turun tipis
Hari 6	1.030	18.100	Harga naik

Angka pada tabel di atas sepenuhnya ilustratif. Tabel ini hanya menunjukkan bentuk data yang dapat dianalisis dan tidak mewakili harga saham aktual atau hasil model.

6.4 Cara Membaca Hasil

Setelah model dijalankan, bandingkan MAE dan RMSE model dengan baseline pada periode testing. Jika model memiliki kesalahan lebih kecil secara konsisten, model tersebut menunjukkan potensi pada eksperimen ini. Jika tidak, model kompleks tidak dapat dinyatakan lebih baik. Selanjutnya periksa periode ketika model sering meleset, misalnya saat harga bergerak tajam, dan uji apakah hasil tetap stabil pada jendela waktu lain.

BAB VI — IMPLEMENTASI DAN PEMBAHASAN

6.5 Contoh Pseudocode

Berikut alur pseudocode untuk menggambarkan proses, bukan program yang telah dijalankan pada dataset nyata:

```
1. Muat dataset harga saham
2. Urutkan baris berdasarkan tanggal
3. Periksa nilai kosong, duplikasi, dan tipe data
4. Buat target = Close pada periode berikutnya
5. Buat fitur lag dan indikator yang hanya memakai data masa lalu
6. Pisahkan data secara kronologis: training, validation, testing
7. Fit preprocessing menggunakan training saja
8. Latih baseline dan model kandidat
9. Pilih parameter berdasarkan validation
10. Evaluasi model final pada testing menggunakan MAE dan RMSE
11. Bandingkan hasil dengan baseline dan tulis keterbatasan
```

6.6 Kesalahan yang Perlu Dihindari

- Mengacak baris time series sehingga urutan waktu hilang.
- Menggunakan data masa depan ketika membentuk fitur atau menghitung skala.
- Mengukur keberhasilan hanya dari data training.
- Mengabaikan baseline yang sederhana.
- Membandingkan model pada periode atau target yang berbeda.
- Menganggap akurasi prediksi sebagai jaminan keuntungan investasi.
- Tidak melaporkan keterbatasan, biaya transaksi, dan perubahan kondisi pasar.

6.7 Keterbatasan Analisis

Analisis harga historis memiliki batasan penting. Informasi publik mungkin sudah tercermin dalam harga, sementara berita, kebijakan, kondisi ekonomi, dan perilaku investor dapat berubah secara cepat. Data harian juga tidak selalu menangkap perubahan intrahari. Hasil dari satu saham dan satu periode tidak otomatis berlaku pada saham lain atau periode berbeda.

BAB VII — KESIMPULAN DAN SARAN

7.1 Kesimpulan

Analisis dataset merupakan fondasi utama dalam membangun model prediksi pergerakan harga saham. Proses yang baik dimulai dari penentuan tujuan dan target, pengumpulan data yang sesuai, pemeriksaan kualitas, eksplorasi, dan pembentukan fitur. Setelah itu, data dibagi secara kronologis agar evaluasi meniru kondisi prediksi nyata.

Berbagai metode dapat digunakan, mulai dari baseline sederhana, model statistik seperti ARIMA, hingga machine learning seperti Random Forest dan deep learning seperti LSTM. Tidak ada satu metode yang selalu terbaik untuk semua saham dan periode. Model perlu dibandingkan menggunakan metrik yang sesuai, diuji terhadap baseline, dan dievaluasi pada data yang tidak digunakan saat pelatihan.

Hal paling penting adalah menghindari data leakage, menjaga reproduksibilitas, dan menafsirkan hasil secara hati-hati. Prediksi merupakan estimasi dengan ketidakpastian, bukan kepastian tentang harga masa depan maupun jaminan keuntungan.

7.2 Saran

- Gunakan dataset dengan sumber, periode, dan definisi variabel yang jelas.
- Mulai dari baseline sebelum menggunakan algoritma yang lebih kompleks.
- Gunakan pembagian data berdasarkan waktu dan pertimbangkan walk-forward validation.
- Laporkan MAE/RMSE atau metrik klasifikasi bersama penjelasan target dan horizon prediksi.
- Jika menilai strategi perdagangan, masukkan biaya transaksi dan risiko.
- Lakukan eksperimen tambahan pada saham, periode, dan kondisi pasar berbeda sebelum menarik kesimpulan umum.

7.3 Penutup

Dengan tahapan analisis yang terstruktur, mahasiswa dapat mengembangkan penelitian prediksi harga saham yang lebih transparan, terukur, dan dapat dievaluasi. Fokus utama proyek akademik adalah metode yang benar dan interpretasi yang jujur, bukan sekadar menghasilkan angka prediksi.

LAMPIRAN — PANDUAN SINGKAT PRESENTASI

Urutan Penyampaian (±8–10 Menit)

Bagian	Durasi	Poin yang disampaikan
Pembukaan	30 detik	Perkenalkan topik dan alasan pentingnya prediksi harga saham.
Latar belakang & tujuan	1 menit	Jelaskan masalah, pertanyaan, dan tujuan analisis.
Dataset & fitur	2 menit	Uraikan kolom OHLCV, target prediksi, dan contoh fitur.
Metode	2 menit	Jelaskan baseline, model pilihan, dan pembagian data berbasis waktu.
Evaluasi	2 menit	Terangkan MAE/RMSE, perbandingan dengan baseline, serta data leakage.
Kesimpulan	1 menit	Tekankan manfaat, keterbatasan, dan bahwa prediksi bukan kepastian.

Contoh Kalimat Pembuka

"Selamat pagi/siang. Pada kesempatan ini saya akan mempresentasikan analisis dataset untuk memprediksi pergerakan harga saham. Pembahasan berfokus pada bagaimana data historis dipersiapkan, bagaimana model dibangun, serta bagaimana hasil prediksi dievaluasi secara objektif."

Contoh Pertanyaan dan Jawaban

Tanya: Mengapa data tidak boleh diacak?

Jawab: Karena urutan waktu penting. Pengacakan dapat membuat model belajar dari masa depan untuk memprediksi masa lalu.

Tanya: Apakah model yang paling rumit pasti paling akurat?

Jawab: Tidak. Model harus dibandingkan pada data uji yang sama dan melawan baseline sederhana.

Tanya: Apa arti MAE?

Jawab: MAE adalah rata-rata selisih absolut antara nilai aktual dan prediksi, dalam satuan target.

Tanya: Apakah prediksi ini bisa menjamin keuntungan?

Jawab: Tidak. Pasar tidak pasti dan hasil statistik belum tentu menghasilkan keuntungan setelah biaya serta risiko.